

Tiebreaking Strategies for A* Search: How to Explore the Final Frontier

浅井 政太郎 東京大学 総合文化研究科 学振DC2

発表要旨

これまでの研究業績

Fully Automated Cyclic Planning for Large-Scale Manufacturing Domains ≪ 1.
ICAPS14.

Solving Large-Scale Planning Problems by Decomposition and Macro Generation ≪ 1. **ICAPS15.**

Tiebreaking Strategies for A* Search: How to Explore the Final Frontier ≪ 1.
AAAI16. (JSAI 学生奨励賞)

Tie-Breaking Strategies for Cost-Optimal Best First Search ≈ 1. **JAIR 58 (2017): 67-121.**

Exploration Among and Within Plateaus in Greedy Best-First Search ≈ 1. **ICAPS17.**

Efficient Optimal Search under Expensive Edge Cost Computation ≈ 2. **IJCAI17.**

Classical Planning in Deep Latent Space: From Unlabeled Images to PDDL (and back) ≈ 1. **KEPS17.**

今後の研究計画, 研究成果の産業応用への抱負

≈ 1 Masataro Asai, Alex Fukunaga

≈ 2 Masataro Asai, Akihiro Kishimoto, Adi Botea, Radu Marinescu, Elizabeth Daly M, and Spyros Kotoulas

1 背景 - AI プランニング



1.1 誰?



And let me introduce these robots. The guy in the left is Astro boy.

1.1.1 誰?

鉄腕アトム



As you know, he is a famous manga superhero invented by Tezuka Osamu in 50s,

1.1.2 誰?

鉄腕アトム



見て,聞いて,喋って,行動する
自律行動 *Autonomous*



and he can think, hear, speak, act. he also has emotions.

1.1.3 誰?

鉄腕アトム



見て、聞いて、喋って、行動する
自律行動 *Autonomous*

T-52 援竜 @北九州消防局
レスキュー・ロボット



In contrast, the guy in the right is a real robot that is actually in use @ fukuoka prefecture for the rescue purpose.. His name is T-52 Enryu, developed by a Japanese company Temzak. He is huge and powerful – about 4 meters in height and can carry things which is as heavy as 500kg. Well, so, in a sense, he is also a superhero in the real disastrous situation.

1.1.4 誰?

鉄腕アトム



見て、聞いて、喋って、行動する
自律行動 *Autonomous*

T-52 援竜 @北九州消防局
レスキュー・ロボット



自律行動 *Autonomous*
?

But does he have feelings or can he think? Can he even move around by his own?

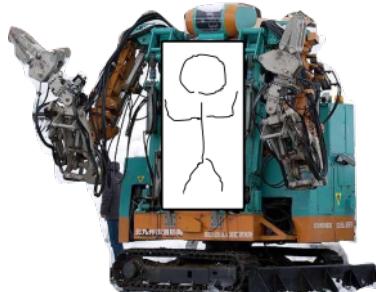
1.1.5 誰?

鉄腕アトム



見て、聞いて、喋って、行動する
自律行動 *Autonomous*

T-52 援竜 @北九州消防局
レスキュー・ロボット



自律行動 ~~X~~ *utonomous*
人間による操作
でかいラジコンショベルカー

No. It requires full human intervention — it is indeed operated by a driver who gets in or by a remote control. It is more like a super-sophisticated shovel car.

1.2 自律行動のための自動プランナ(≠ モータ制御)

プランナ=抽象行動列を求める人工知能プログラム



初期状態: 人が生き埋め!



出力: 被災者を助ける

アクション列 = プラン

ゴール: 患者の搬送

プラン:

出血をとめる

→病院に電話

→患者を助け出す

→救急隊に引き渡し

研究テーマのプランニングは、ロボットに、人間の助けを借りず、いかに自律して行動させるかを扱います。これをモデル化したプランニング問題は、具体的な行動の列を求める組合せ最適化問題です。

プランニング問題のタスクは、センサーから初期状態とゴールを受け取って、被災者を助ける正しい手順を出力することです。たとえば、この図では男性が瓦礫に埋まって助けを求めていました。プランニング機能のあるロボットは、コレに対して「男性を助けよ」という大まかな指示を受けます。

1.3 自律行動のための自動プランナ(≠ モータ制御)

プランナ=抽象行動列を求める人工知能プログラム



初期状態: 人が生き埋め!

出力: 被災者を助ける

アクション列 = プラン

ゴール: 患者の搬送

プラン:

出血をとめる

→病院に電話

→患者を助け出す

→救急隊に引き渡し



一階述語論理で入力

初期状態

出血(浅井)

on(木材, 浅井), on(岩, 木材)

アクション

電話(病院)

救出(浅井)

ゴール

引き渡し(浅井, 救急車)

at(浅井, 病院)

指示の内容には、図のように初期状態とゴール、許可された行動のリストが入っています。ロボットは、自動プランニングにより、人間の代わりに適切な行動を組み立てて、ゴールを自動で達成します。

1.4 自律行動のための自動プランナ(≠ モータ制御)

プランナ=抽象行動列を求める人工知能プログラム



初期状態: 人が生き埋め!

出力: 被災者を助ける

アクション列 = プラン

ゴール: 患者の搬送

プラン:

出血をとめる

→病院に電話

→患者を助け出す Mars Exploration Rover

→救急隊に引き渡し (Bresina et al. '05)

汎用性
ゆえに
様々な
応用例



プランニングの
応用実績

Deep Space 1
(Muscettola
et al. '98)



Mars Exploration Rover
(Bresina et al. '05)



CORE SECURITY[®]
Thinking Ahead.

ネットワークの自動ハッキング
→脆弱性を報告

一階述語論理で入力

初期状態

出血(浅井)

on(木材, 浅井), on(岩, 木材)

アクション

電話(病院)

救出(浅井)

ゴール

引き渡し(浅井, 救急車)

at(浅井, 病院)

問題を論理で記述→
目的達成の手段を
自動で計算可能

プランニングは汎用な枠組みなので、災害救助以外にも様々な問題に適用することができます。現実の応用例では「宇宙探査機運行問題」や「企業ネットワーク脆弱性問題」も表現できます。

このように、プランニングは、難しい問題を汎用性を失わずに解くことを目指します。

1.5 プランニング(自動行動計画)分野の位置づけ

プランニング分野は、人工知能の専門分野という位置づけで、隣接するオペレーションズ・リサーチやアルゴリズム論などの分野の技術を利用しています。特に、プランニング問題を解くのにはグラフ探索の技術が用いられます。

プランニングの計算複雑性クラス:
仮定を加えてもNP困難

PLANSAT は PSPACE完全

探索空間のサイズは命題に対して指数:
探索グラフの頂点数 = $2^{(\text{命題変数の数})}$
変数100個 → 2^{100} 120個 → 2^{120}

コンパイル=プランニング
機械語1命令=アクション

プランニングのモデル言語 PDDL
の記述力は?

計算量理論
アルゴリズム論
グラフ理論

情報システム

コンパイラ,
プログラミング言語

AI

論理・知識表現
進化計算 機械学習

探索アルゴリズム(A*)

プランニング
スケジューリング

プランニング分野の主要国際会議:

International Conference on Automatd Planning and Scheduling (ICAPS) (1994-),
および AAAI, IJCAI

主要研究グループ: MIT CSAIL, CMU, NASA/
Caltech JPL, NASA Ames, 欧州宇宙機関
(ESA)など

SAT, 制約充足
整数計画

MDP, POMDP

OR
(オペレーションズ
リサーチ)

倉庫管理問題
ロジスティクス問題
電力網最適化

プランニングの主な手法:

頂点ノードV:状態, 辺E:アクション
である有向グラフ(V,E)の経路探索

初期状態
at(key, 部屋C),
at(ロボット, 部屋B),
¬clean(部屋A),
¬clean(部屋B)....

at(key, 部屋C),
at(ロボット, 部屋C)...

move(部屋B, 部屋C)

cleanup(部屋B)

ゴール

pickup(key)

ゴール

ゴール

ゴール

1.6 業績1: 査読付き国際学会 ICAPS14 (採択率33%)

セル生産方式: 工場生産方式の一種 (対義語: ライン生産)

ロボットアームなどを含む小規模セルが複数協調して製造

目的: 並列の製造プランを自動計画 + 製作時間を最小化

一台の組み立て問題を解くのはある程度複雑でも可能

研究の対象

✗ アクチュエータの角度制御 (例: $\theta: 0\text{deg} \rightarrow 30\text{deg}, 1\text{deg/sec}$)

◎ 行為の計画(例: 部品2をアーム1で塗装, ネジ3を締結 etc.)

問題点: 扱う対象の数が多くなる場合 (製品が4個程度以上の時)

最適解を返すソルバで直接解く → ✗ 探索空間が広大で探索不可

1つ分の製造手順を複数つなげて後処理最適化 → ✗ 生産時間が長い
(makespan)

手法: 問題の繰り返し構造を「工場, セル生産, 製品」など前提なしに
任意のプランニング問題の論理構造から自動検出

検出した繰り返し構造から効率よい (生産時間の短い) プランを生成

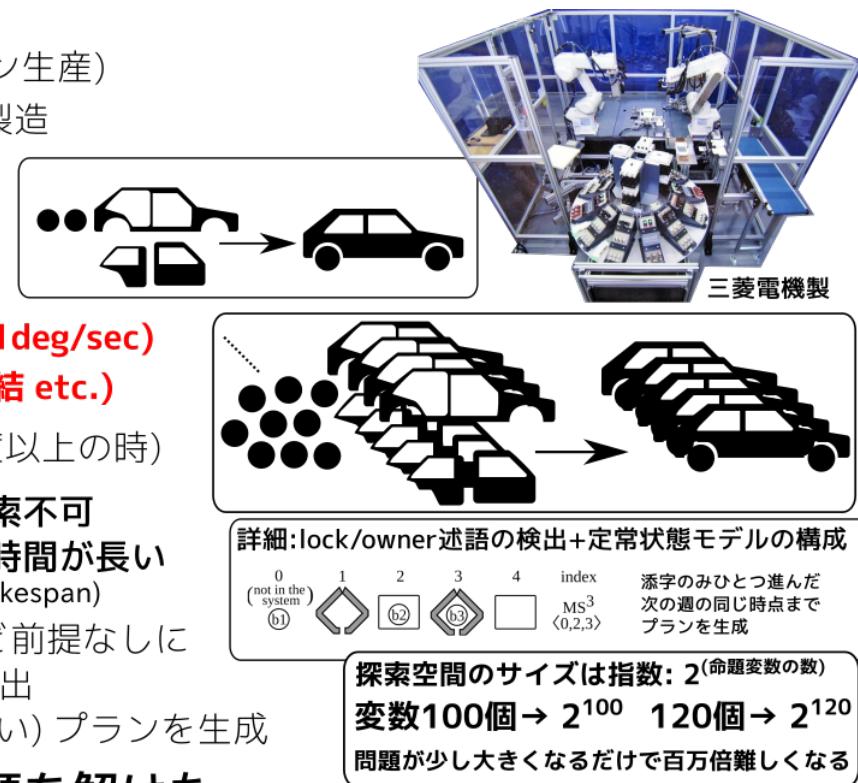
**結果: 1000台以上の製品を組み立てる問題を解けた
+ 生産時間を最大3割短縮(後処理最適化と比較)**

新規性: 繰り返し構造を自動で抽出するというアイディア+抽出技術

インパクト: 大きな高速化, プランニングの適用規模を広げた

株式会社IHIと共同研究(システムの先行評価として)

研究業績に移ります。ここでは、大規模なプランニング問題を解くために問題設定・ドメインによらず汎用に繰り返し構造を抽出する方法を開発しました。元の問題を繰り返し一周分の小問題に分割して解くことで、高速化と3割の生産時間短縮を達成しました。大切なのは汎用性です。生産問題に限らず、掃除にも宇宙船にも同じ実行バイナリが使えます。



→ しかも探索空間はその指数で増加
解ける探索空間のサイズ:

以前: $10^6 \rightarrow$ 提案手法: 10^{274}

1.7 業績2: 査読付き国際学会 ICAPS15 (採択率33%)

プランニング分野一般の目標:

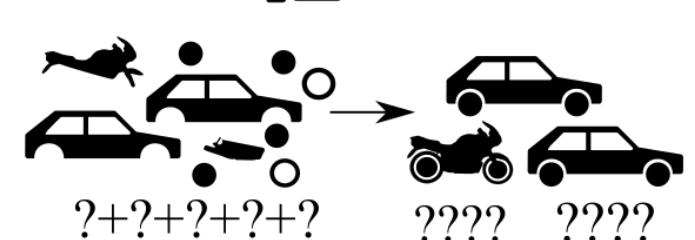
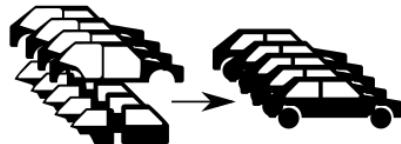
汎用性を失わずにより複雑な問題を解く! → 高度なAI

ICAPS14を一般化すればはるかに困難な問題が解けるハズ

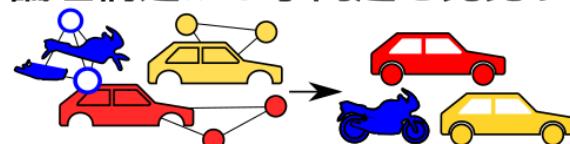
探索空間のサイズは指數: $2^{(\text{命題変数の数})}$

変数100個 → 2^{100} 120個 → 2^{120}

問題が少し大きくなるだけで百万倍難しくなる



手法: **問題の論理構造から小問題を発見する新手法**



分割なしでは解けない問題
(探索失敗)

より柔軟な統合手法

既存手法 全プラン
分割結果のみからプラン生成
汎用性(低) 特定条件のみで動作

提案手法 全プラン
分割前のモデルを併用
統合が失敗するときも適用可能
使われなかった小問題

結果: **広い問題種別で**
3-4倍変数の多い問題を解けた
解ける探索空間のサイズ:
以前: $\sim 10^7$ 提案手法: $\sim 10^{28}$

新規性: 小問題の発見手法 / 柔軟な統合手法
インパクト: 高速化, 小問題分割の汎用性を実証

続いて二、三本目の業績は、先ほどの手法で得られるのは1種類の小問題だけでしたが、これを複数種類の小問題に拡張しました。結果、より様々な問題で高速化を達成しました。ここまで汎用に小問題分割を適用した研究は、分野では始めてです。

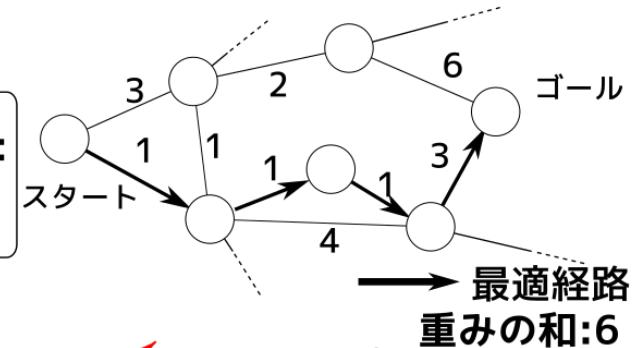
1.8 業績3: 査読付き国際学会 AAAI16 (採択率26%)

グラフ探索一般に適用できる高速化手法の開発

グラフ探索: スタートからゴールまでの経路を探す
+ 通る辺の重みの和を最小化する

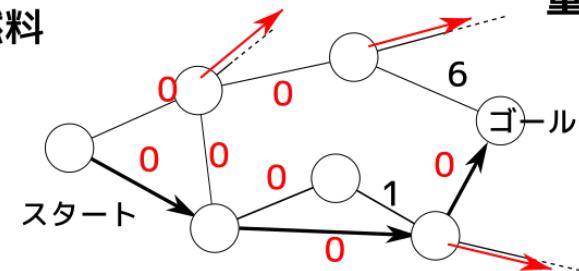
身近な例: カーナビ 但し、本研究の対象は
メモリには収まらない規模のグラフを扱う
例: アミノ酸の多重配列問題(MSA)など
プランニング問題もグラフ探索で解く

著名なグラフ探索アルゴリズム:
Dijkstra法 (1959), A*(1968)



複雑/実用的な探索問題には重み0の辺が大量にある (指数的に多い)
例: トラックの配達計画 (燃料を最小化) 辺=行為, 重み=燃料
→荷物の積み替えには燃料を使わない

問題点: 重みの和が同じノードが大量に存在
探索を進める方向を見失う → タイブレークの影響大



オリジナリティ: A*(見積もり値を用いた最良優先探索(最良分枝限定法))にて

1. タイブレークに関する70年代からの定説を覆した
2. タイブレークの新手法を提案し性能向上

結果: 解ける問題規模が拡大 (ベンチマーク1104問:814問 → 867問 (+53問))

解ける問題の探索空間サイズ(例):
(企業ネットワーク脆弱性の診断問題にて) 以前: 10^6 提案手法: 10^{88}

今後のインパクト: 重み0の辺を持つ広範なグラフ探索問題に対して性能向上

最後に、申請後に行った研究が、難関国際学会 AAAI に採択されました。研究内容は、コスト0の辺を含むグラフを扱うグラフ探索アルゴリズム一般に適用できる内容で、非常に大きなインパクトを持つことが考えられます。

AAAI16の一般化: タイブレーク≡非最適探索

問題点: 重みの和が同じノードが大量に存在 (ゼロコスト問題)

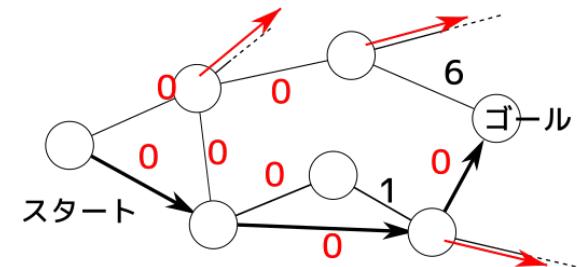
探索を進める方向を見失う → タイブレークの影響大

ノードの下界関数 h の種類

許容的: 常に真のコストより低く見積もる → 最適解

非許容的: 非最適解を見つけてしまう ← 従来は使われない

Unit cost 関数: 辺コストを全て1で代用, 非許容的関数の例



主な発見: タイブレーク とは 許容的関数 h で作ったプラトーの中で非最適探索を行うことである

新規性: 最適探索で非許容的関数を効果的に使う方法を初めて示した

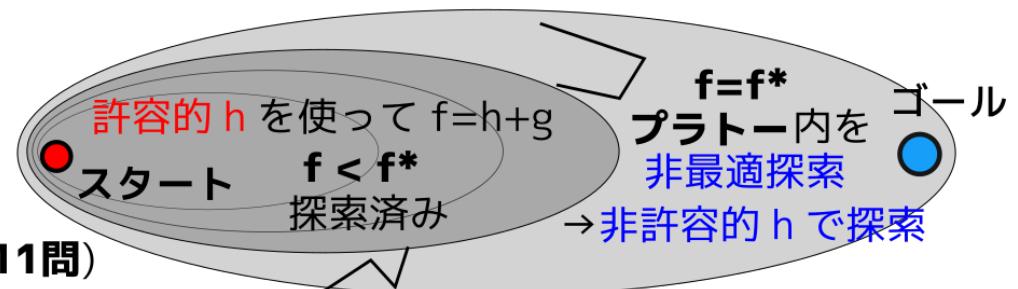
性能評価:

ゼロコスト問題のタイブレークに

非許容的 Unit cost 関数を使う

→ 指数的に高速化 (844問 → 906問)

→ AAAI16と同時使用でさらに高速 (→ 911問)



理論的成果:

無限グラフでのA*の完全性を

様々なタイブレーク法ごとに証明

→ 非最適探索の理論的結果を援用

非最適探索用の全技術を最適探索に援用可能
(従来は非互換と考えられてきた)
→ 今後のさらなる発展が期待できる

1.10 業績5: 査読付き国際学会 ICAPS17 (採択率33%)

スキップ予定

非最適探索の均一化手法の理解と改善

非最適探索: GBFS (貪欲最良優先探索) + **非許容的** 下界関数 h

下界関数 h を常に信頼して(**貪欲**)探索を集中させる(exploitation)

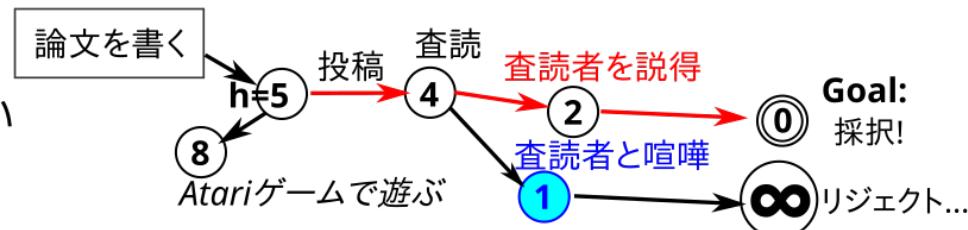
→**非許容的** h は常に正しいとは限らない → h を時折無視して探索を**均一化**→性能向上

(exploration/
diversification)

問題点: アドホック手法が多い

→どう組み合わせればよいか解らない

目的: →クリーンに評価しなおす



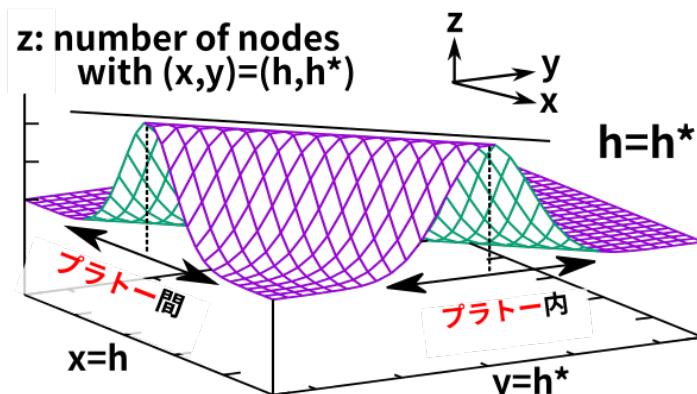
発見1. 2つの直行した均一化方法がある。

理由: 真の値 h^* からの h の誤差は二次元的

→ **プラトー間**均一化と **プラトー内**均一化

→同じ均一化手法を二通りに利用出来る

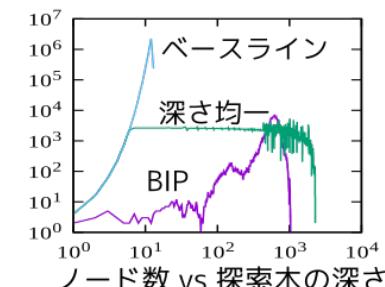
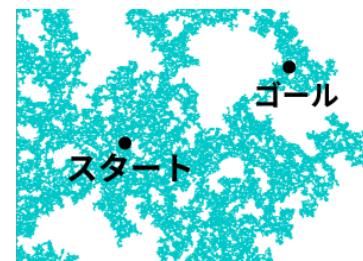
→直行だから同時利用してOK! → 性能向上



発見2. ボンドパーコレーション(BIP)

フラクタルを使った均一化手法

→ 性能向上の理由: 探索木の幅を削減



制限時間内で解けた問題数: 192 → 237.7

参考: [Xie et. al. 2014] 深さ均一化 223.9

1. 未知の均一化アルゴリズムに汎用に適用できる法則
2. フラクタルを用いてより良い探索が出来る可能性

1.11 業績6: 査読付き国際学会 IJCAI17 (採択率25%)

辺コスト動的計算が必要なグラフ探索の高速化

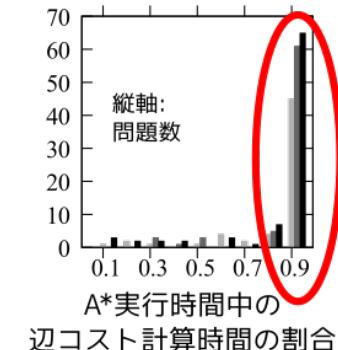
(IBM Research Ireland での研究)

問題点: 一回の辺コストを求める計算(外部ソルバ)が重い

→全コストを求めるのが現実的でない

→A*探索で必要になった辺コスト c_a のみを動的に計算

→それでもなお実行時間の90%を辺コスト計算に使用



例1: 辺コスト(都市間距離)が未知のTSP

都市数Nに対し $O(N^2)$ 回経路探索ソルバを呼び出す

例2: MWRP (複数ワーカー乗り換え問題):

[地図上の全場所] $^2 \times$ [全出発時刻] 個の二点間乗り換え

→ 全ての辺コストを求めるのは現実的でない

→ コストを求めた後の問題自体もNP困難

在宅訪問診療のモデル問題

医者が患者を予約時間に訪問する最適乗り換え計画



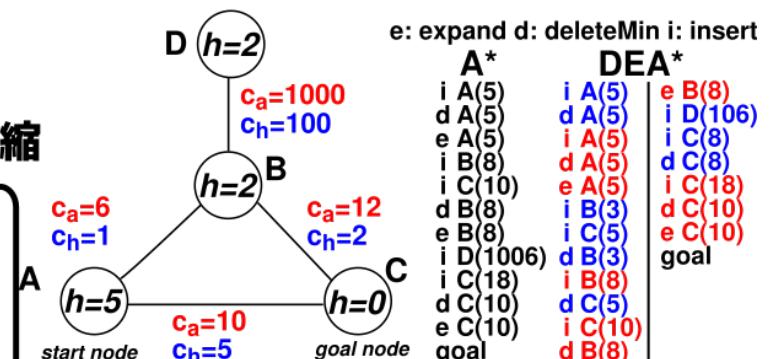
解決法: c_a の下界 c_h で代用、必要になるまで c_a 計算を遅延

c_h : 外部ソルバの下界閾値, c_a より高速に計算可能

同じノードを c_h/c_a で二回展開・キューに挿入

→多くの c_a を計算せずにすむ → 探索時間を最大5倍短縮

多くの実問題は階層構造を持つ
既存外部ソルバを用いて汎用に適用可能



2 産業技術総合研究所で行いたい研究

Neural-Symbolic複合システムによる

次世代AIシステム

の研究

2.1 Q. いまはやりの Deep Learningとの違いは?

A. レイヤが違う

機械学習・**Neural Networks** == 関数

近似

for 認識・反射

- 入力は **Subsymbolic** (連続値)
画像、音声、非構造化テキスト:
- 感覚的知能:

反応, 直後の行動の決定
パブ

ロフの犬: 餌を認知 → よだれ

自動運転: 赤信号, 人 → 止まる.

翻訳: 文章 → 文章

囲碁局面の評価関数: 局面 → 勝率

効率よく 1-to-1 mapping

単純作業

- AlphaGo = Subsymbolic (DLNNによる評価関数) + Symbolic (MCTSによる探索)

推論・探索

for プランニング・ゲーム・定理証明

- 入出力は **Symbolic**
論理オブジェクトルール
- 論理・推論による知能:
 - 未来に渡る 戰略の決定
(戦略 = 行動の列や木) レス
 - キューロボ: ゴール = 被災者生存
 - 証明器: ゴール = QED
 - コンパイラ: 命令列の生成
 - 囲碁, 将棋: ゴール = 勝利 順序制約+複雑な作業

2.2 既存の有名システム

AlphaGo = Subsymbolic (NNによる評価関数) + Symbolic (MCTSによる探索)

- ただし ドメイン依存 – 囲碁に特化, ”マス目”や”石”といった概念をハードコード
- 膨大な棋譜が必要 – 運用データがない環境(e.g. 火星)には適用不能
- 人って模範解答がないと行動できませんか? 真の自律機械は前例無しでも行動可能

DQN = Subsymbolic (DLNN) + 強化学習 (DLNN)

様々な Atari Game につかえる汎用フレームワーク (Invader, Packman…) だが

- RL の Acting: 学習した policy に従って greedy に行動
- Atari ゲームは 脊髄反射で生き残ることが可能 → 複雑な論理思考はいらない!

2.3 記号的AIによる論理推論の重要性

f Conclusions

Y LeCun

- Deep Learning is enabling a new wave of applications
 - ▶ Today: Image recognition, video understanding: vision now works
 - ▶ Today: Better speech recognition: speech recognition now works
 - ▶ Soon: Better language understanding, dialog, and translation
- Deep Learning and Convolutional Nets are being widely deployed
 - ▶ Today: Image understanding at Facebook, Google, Twitter, Microsoft.....
 - ▶ ... for medical image analysis, robot perception
- We need hardware (and software) for embedded applications
 - ▶ For smart cameras, mobile devices, cars, robots, toys....
- But we are still far from building truly intelligent machines
 - ▶ We need to integrate reasoning with deep learning
 - ▶ We need a good architecture for “episodic” (short-term) memory.
 - ▶ We need to find good principles for unsupervised learning

2.4 業績7: 査読付きワークショップ KEPS (採択率 60%)

深層学習(非記号型AI)と行動計画(記号型AI)の融合

画像で示された問題を

「パネル」「9マス」「動く」などの情報は一切与えられない問題を解いた例も与えられない



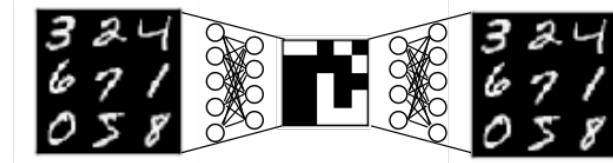
Initial state
image



Goal state image
(black/white)



Original
Mandrill image



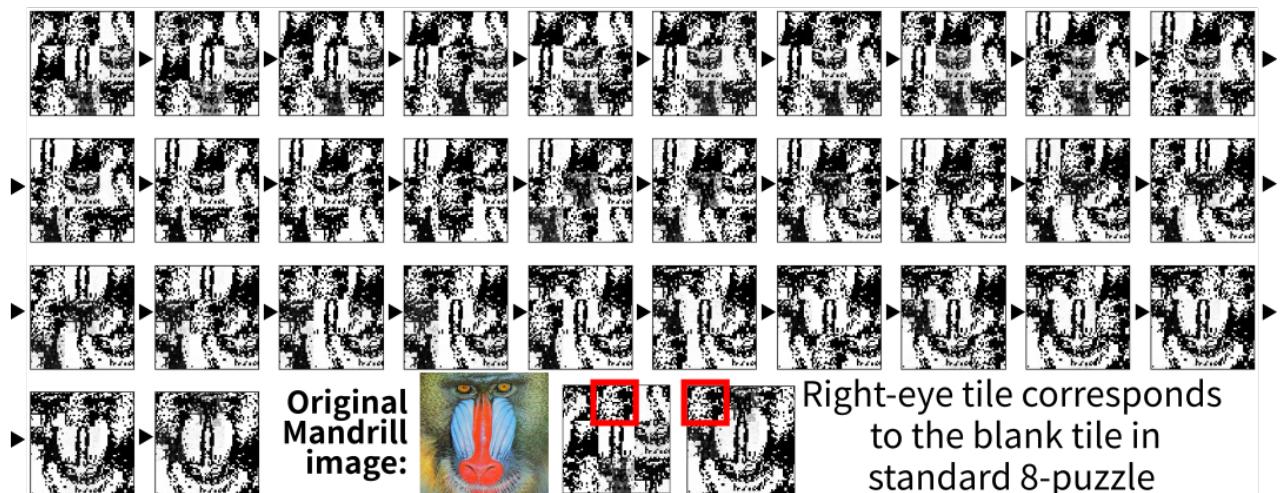
Variational AutoEncoder

Gumbel-Softmax を用いたVAEで
記号的命題表現に自動的に変換し
記号的プランニングソルバで解く

ノードの数を減らしてから元のサイズに戻す NN
入力画像と出力画像が一致するように学習
かつ、真ん中の層は0/1値: 何らかの命題の真偽値に対応

結果を画像に戻して
プランを返却する
システム

LatPlan



Original
Mandrill
image:

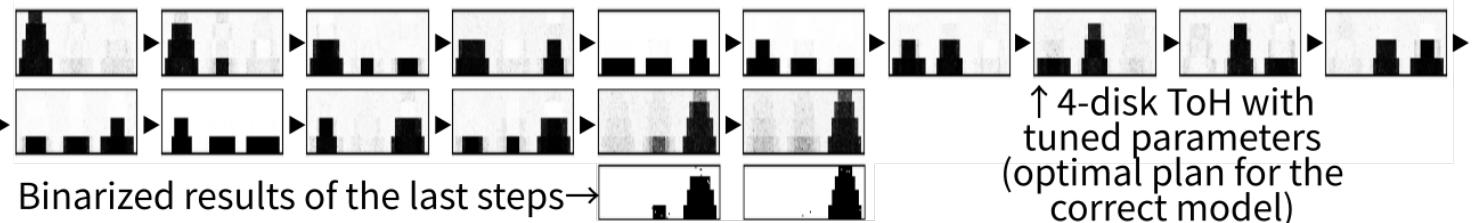
Right-eye tile corresponds
to the blank tile in
standard 8-puzzle

2.4.1 研究業績7：査読付きワークショップ KEPS (採択率60%)

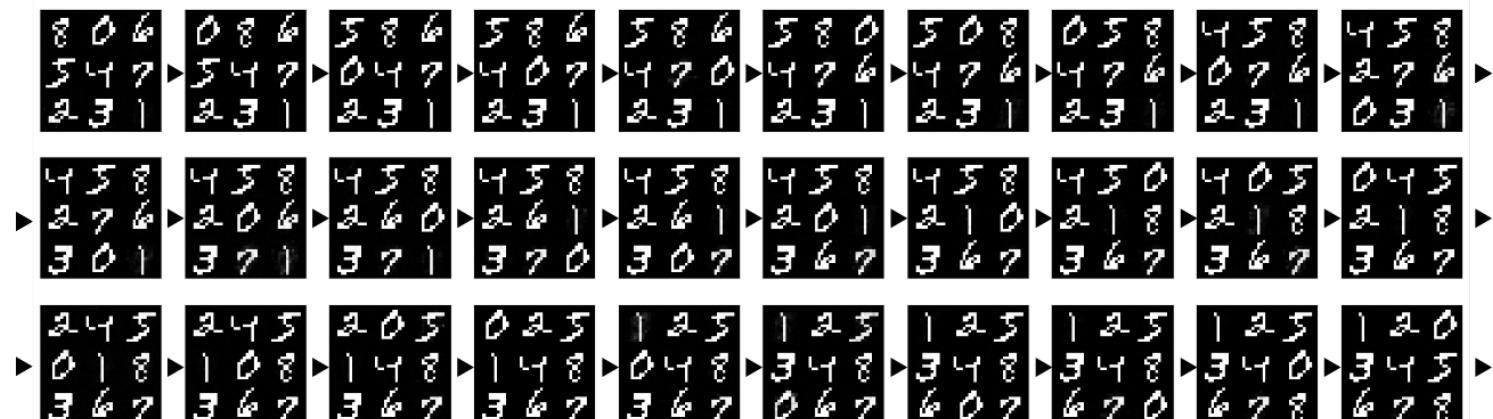
LatPlan: 同じシステムで全く異なる問題を解ける

問題ごとにニューラルネットの学習は必要

ハノイの塔



数字版
8-パズル

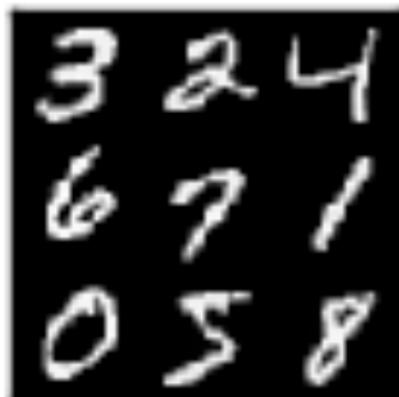


LightsOut



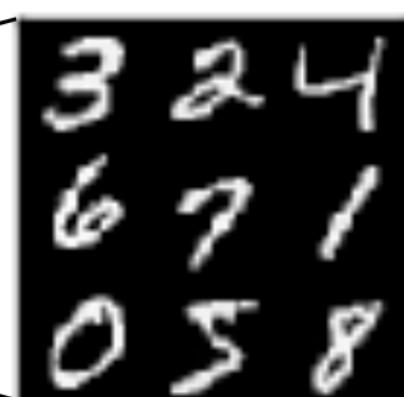
2.4.2 SAE のもっとちゃんとした解説

84x84 入力画像



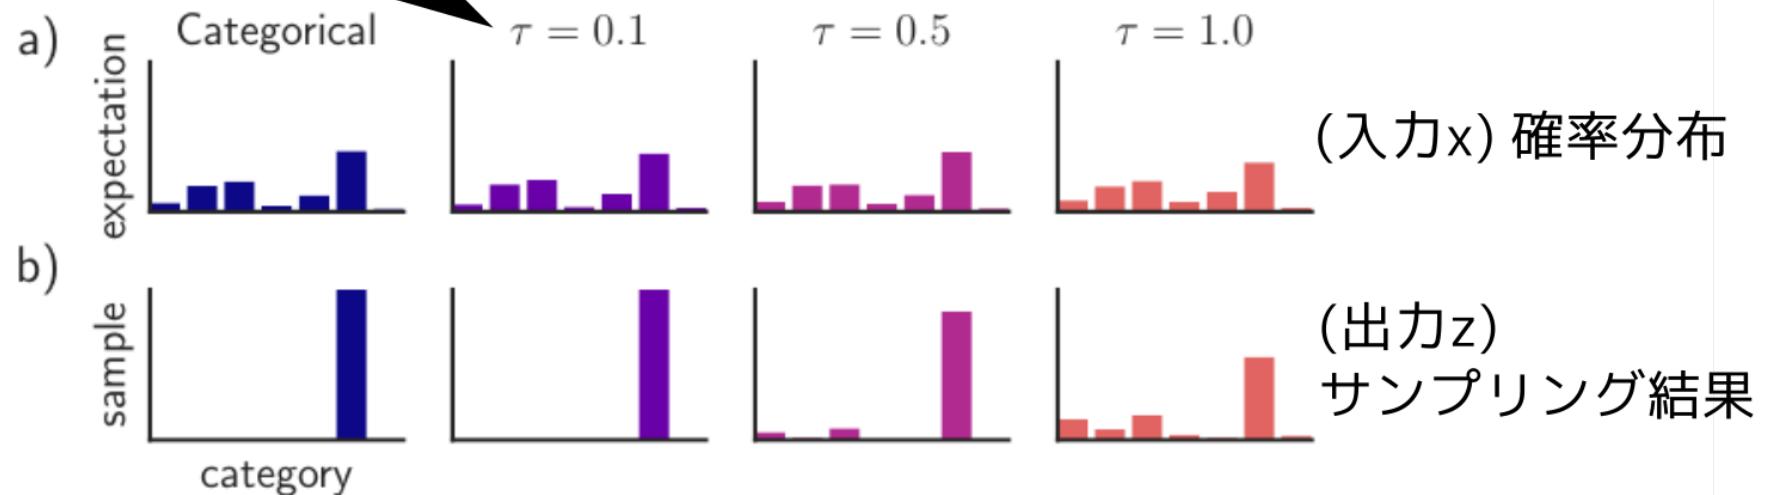
49bit
latent
bit-vector

84x84 復元画像



ノードの数を減らしてから元のサイズに戻す
ニューラルネットワーク
入力画像と出力画像が一致するように学習
かつ、真ん中の層は0/1値: 何らかの命題の真偽値に対応

温度を徐々に下げることで連続に近似
→微分可能、BP学習可能



2.4.3 研究業績7：査読付きワークショップ KEPS (採択率60%)

強化学習とは異なり、優れた理論的性質

アルゴリズムの完全性: 解が存在するときには必ず解を発見する
解の最適性: 理論的性質のわかっている下界関数を使うことで保証

	入力・認識	意思決定
DQN	画像・ニューラル (事前知識なし)	Greedy+NN強化学習 =反射的エージェント
AlphaGo	ハードコード ("石","マス目")	記号的 MCTS+NN強化学習 学習結果に理論保証なし ($t \rightarrow \infty$ での収束保証のみ) vs. イ・セドル 白74手 大幅に読み違え
LatPlan	画像・ニューラル (事前知識なし)	A*+許容的下界関数 (完全性+解の最適性)

ニューラル認識と記号的意味決定(理論保証付き)を持つシステム

認識の誤差(NNに起因)はあっても意味決定の誤りは無い

2.5 今後の研究計画

LatPlanの様々な発展形を実現

画像で示された問題を

「パネル」「9マス」「動く」などの情報は一切与えられない問題を解いた例も与えられない

Gumbel-Softmax を用いたVAEで
記号的命題表現に自動的に変換し
記号的古典プランナで解く

結果を画像に戻して
プランを返却

目標:

Neural-Symbolic 複合システムの
standard として地位を確立

音声で?

テキストで?

音声用オートエンコーダ or
テキスト用オートエンコーダ
にGumbel-Softmaxを適用
word2vec → エッフェル塔 - フランス + 東京 = スカイツリー
古典プランナと組合せ → 数千ステップ言語レベル推論

一階述語表現に?

R-CNN によるオブジェクト認識
predicate(obj1, obj2)

より少ないデータから

Domain Model Acquisition:
汎化された状態遷移規則の獲得

記号的非古典プランナ

(並列, 階層的, 確率的, 不完全情報)
Temporal HTN MDP POMDP

外界

センサ

NNに基づく認知
記号論理による判断

3 研究成果の産業応用

記号的推論によりブレークスルーをもたらしうる

ピックアップロボ以上の産業用ロボ

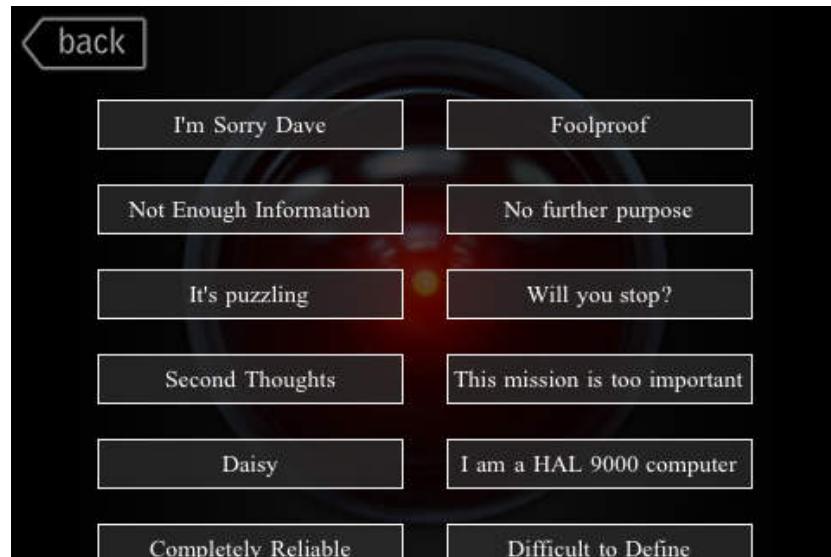
— 画像 → 論理表現 → 記号的推論

→ 行動決定

— 動的な環境や目標に自動で対応
できる

人工無能以上のチャットボット

— テキスト → 論理表現 → 記号的
推論 → 意図推定 → 返答



4 まとめ

1. 難関国際会議 (33%) Fully Automated Cyclic Planning for Large-Scale Manufacturing Domains. In ICAPS2014.
 - (a) 任意の問題から 1 種類の繰り返し構造を自動で検出
 - (b) 工場での製造スケジューリング ($\times 1000$ 高速化, 探索空間 $10^6 \rightarrow 10^{274}$)
2. 難関国際会議 (33%) Solving Large-Scale Planning Problems by Decomposition and Macro Generation. In ICAPS2015.
 - (a) 複数の繰り返し構造をより柔軟・汎用に組み合わせる手法
 - (b) ベンチマークセット全体で高速化 ($\times 3\text{-}4$ 高速化, 探索空間 $10^7 \rightarrow 10^{28}$)
3. 難関国際会議 (26%) Tiebreaking Strategies for A* Search: How to Explore the Final Frontier. In AAAI-2016. (JSAT 学生奨励賞)
 - (a) コストゼロの辺がグラフ探索に引き起こす問題を解決 (探索空間 $10^6 \rightarrow 10^{88}$)
4. 難関論文誌 (12%) Tie-Breaking Strategies for Cost-Optimal Best First Search. Journal of Artificial Intelligence Research 58 (2017): 67-121.
 - (a) (3.) に加え タイブレーキングと非最適コスト探索の関連性を指摘, さらに性能向上
5. 難関国際会議 (33%) Exploration Among and Within Plateaus in Greedy Best-First Search.

以上です、ありがとうございました。

In ICAPS2017.

- (a) 非最適コスト探索をフラクタルを用いて改善
- (b) プラトー内均一化とプラトー間均一化の直交性を実証

6. 難関国際会議 (**25%**) Efficient Optimal Search under Expensive Edge Cost Computation. In IJCAI-2017.

- (a) 辺コストの動的計算が必要な問題に対して高速な最適アルゴリズム DEA*

7. 国際ワークショップ (**60%**) Classical Planning in Deep Latent Space: From Unlabeled Images to PDDL (and back). Knowledge Engineering for Planning and Scheduling (KEPS) Workshop

- (a) 画像から命題を自動生成して記号的AIで組合せ最適化問題を解き、画像で出力するシステム

5 付録

5.1 NeuroSolver との違い

5.2 neural heuristic との違い

5.3 LfOとの違い

5.4 プランの評価手法

5.5 付録 古典プランニング問題とは (定義)

アクション集合 A , オブジェクト集合 O , 初期状態 I , ゴール G

状態 := 真である命題の集合

アクション $a \in A : ; pre(a), add(a), del(a), cost(a) ;$

ただし、 $pre(a)$: 前提条件, $add(a)$: 追加効果, $del(a)$: 削除効果, $cost(a)$: アクションの適用コスト

状態 s に対するアクション a の適用: $pre(a) \subseteq s$ の時に適用可能で、

$$a(s) = (s \cup add(a)) / del(a)$$

終了判定: $s \supseteq G$ ならば ゴール達成

5.6 付録 古典プランニングを研究する意義は?

"古典"プランニングを研究する意義は?

古典プランニングは

様々な拡張のベースとなる **最小限** のフレームワーク

実験は 古典プランニングでやった というただそれだけ

← 古典プランニングでは評価がやりやすい

- ・ 単純なモデル
- ・ 詳細が調べつくされている
- ・ 何が性能向上の理由なのか切り分けやすい(差分が取りやすい)

直接の実用的な
意義もある



Deep Space 1
(Muscettola et al. '98)
宇宙船の自律航行



Mars Exploration Rover
(Bresina et al. '05)
火星探査ロボットの
自律行動システム



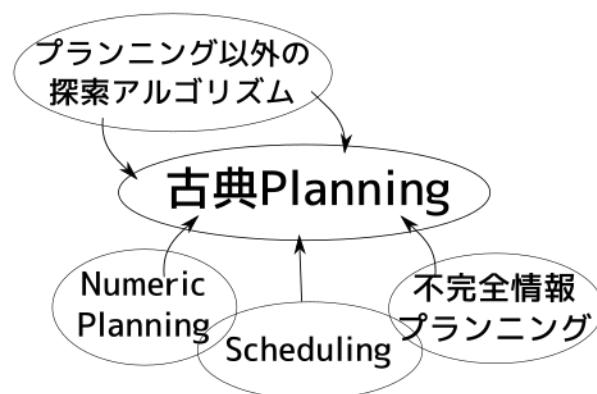
Xerox Parc Printer
大規模 商業印刷システムの
自律運用



Core Security (サービス企業)
企業ネットワーク脆弱性の自動診断
攻撃プランの自動生成

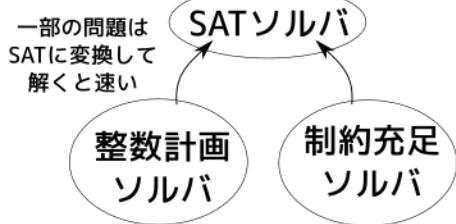
様々な拡張の「基礎」となる基盤技術

古典プランニングで成功した技術は
他の問題にも使える!



類似のシナリオ:SATソルバ

同じく基礎的なモデル



一部の問題は
SATに変換して
解くと速い

5.7 付録 AIの倫理について

- 研究内容は 漠然とした「AI」のうち グラフ探索 の研究
- 善悪の判断はそれ自体は行わない
- 値値判断は与えられる入力の中にある = 使用者の価値観を反映する
- 悪用の問題はある。しかし、自分としては、災害救助ロボットなど、人道的な応用を目指している

5.8 付録 ディープラーニングとどう違うのか

- 機械学習を埋め込むことは可能だ
- が、求められる推論の複雑さが根本的に違う → 独立した分野

ニューラルネット, DL, 強化学習

- 入力: 現在のデータ、過去の履歴、報酬 etc..
- 出力:
 - 次の1ステップのアクション選択
ポリシー (強化学習)
 - 固定長の分類結果 (画像認識)
 - ある意味 状況に応じて脊髄反射
なエージェント

ただしプランニングに学習機を埋め込むことは 可能 (実例複数あり)

DLから見て、プランニングは アプリケーション

プランニングから見て、DLは ツール

両者の組み合わせは機会があればやってみたい

プランニング出力:

- **10ステップ, 100ステップ**
先の未来を 先読み した
行動計画
- ICAPS14,15 の手法を使
えば 数千ステップ 先の
未来まで先読みするこ
とが出来る

5.9 付録 ディープラーニング関連

趣味の一環で、Common Lisp から直接使える GPGPU のライブラリを作成中
(DL を作ってみるため)

- OpenCLベース
- Lisp の文法を直接 OpenCL C に変換し実行するトランスレータ
- OpenCLのメモリ管理を Lisp GC に埋め込み

5.10 付録 第五世代コンピュータとの違いは?

第五世代コンピュータ：並列推論機械(Prologベース, ハードウェア, OS)

根本的なソフトウェア技術、探索技術が未発達だった

第五世代

現在

後方全探索+バックトラック 前方ヒューリスティック探索

Prologベース C/C++で高度に最適化されたプログラム

State packing, 決定木, mutex...

今はベンチマーク問題 **1104問** のうち 5分で **800問** 前後解ける

仮に当時のソフトウェアを現在のハードウェアで動かしたとしても、**100問**も解けないだろう

5.11 付録 Explicit Graph と Implicit Graph との違い

カーナビ、ソーシャル
グラフなど : Explicit
Graph Search

グラフ全体がメモリ
(~数ペタバイト)または
は二次記憶 (~数ゼタ
バイト)に収まる

参考: 2012 年の全世界のデジタルデータ:
数ゼタバイト (1ZB =
 10^{21} バイト)

AI and Web の分野など

プランニングにおける探索グラフ : Implicit
Graph Search

地球上に存在する全計算資源を集めて二次記憶
に入らない

グラフのノード数は状態変数に対して 指数的に
増加

動的に必要な量のみメモリ確保をしないと問題
が解けない

探索空間サイズの例:

3x3x3 のルービックキューブ: $4.32 \times 10^{19} = 4$ エ
クサバイト

4x4x4 のルービックキューブ: $7.40 \times 10^{45} \approx 10^{24}$
ゼタバイト

5x5x5 のルービックキューブ: 2.83×10^{74}

5.12 付録 似たような研究は誰がやっていますか どこでやられていますか

国内ですか、国外ですか？

YES NO

5.13 付録 プランニングはマイナーで大したことのない分野?

日本にプランニングの研究室がない ≠ 世界で研究室がない

ICAPS, SoCS : 例年 150 人-200 人の参加者を集めており大変盛況,

AAAI, IJCAI : プランニングに関する論文は例年数十本採択 Proceedings の一つの章をなす

JAIR, AIJ : 論文誌でもプランニングの論文が多い (JAIR Volume 54: 12 本中 2 本がプランニング論文)

主な研究室:

MIT CSAIL (Brian Williams), Carnegie-Mellon,

NASA (NASA Ames および NASA/Caltech JPL のそれぞれに 20 名以上の研究者), 欧州宇宙機関(ESA)

指導教員は NASA JPL AI Lab の元メンバー

5.14 付録 汎用性を失わずに解く？

No Free Lunch 定理: 最適化アルゴリズムの性能は 全問題の平均を取れば 全て同じ

Q. NFL定理のもとで「汎用性を失わずに高速に解く」というのは不可能?

A. NFL定理は確かにそのように主張するが、プランニング分野の意味する「汎用性」は

人間にとて有意義な問題の集合 における汎用性である。

全プランニング問題の集合 \supseteq 人間にとて有意義な問題の集合

従って、全問題の平均を取れば という前提が成り立たない。

5.15 付録 その研究は...

重要度	評価	オリジナリティ	過去のインパクト
ACP	発表した 難関学会	ループの概念を検出	はるかに巨大化
CAP	難関学会 発表した いくつか質問された メールやり取り	問題分割手法 柔軟な統合手法	大規模な問題 それまでの手法 広範囲に分担
AAAI16	三人中 二人の査読者に絶賛された	同コストのノードの分類	70年代から 通常と異なる コスト0は実現
過去全体			

5.16 国内で誰が似たようなことをやっているか

この専門分野をやっている人は少ないんですが、少し離れているが最も似ている研究というと

SAT ソルバの研究の人はいる – 田中先生

推論系 – logic and reasoning

Lemma Reusing for SAT based Planning and Scheduling ICAPS 10年ぐらい前
NII の井上勝海 CSP でプランニング

神戸大学田沼先生 SAT

九大 横尾誠先生 AAMAS マルチエージェント CSP

自分の指導教官がアメリカから飛んできた研究者なので、もともと日本にいなかつた研究者だった

スライド2を見せる

ERATO の人は同じくグラフ探索をやっていますが、explicit/implicit の違いがあります。瓦林先生秋葉さん

Katsutoshi Hirayama, Kobe university (constraint optimization, CSP, distributed CSP)

Toru Ishida (Kyoto U. stopped working in search a long time ago, but for a while, he was the leader in A*-related search methods in Japan; coauthored some papers with Korf).

5.17 付録 学会論文の位置づけ

5.18 HTN と ICAPS-15 の違い

HTNは人間が問題分割を行う人件費を考えると非常にコストパフォーマンスが悪い→自動で問題分割

5.19 付録 Q&A

- Q. 探索空間の比較について、なぜ「以前」の数字がスライドによって変わるもの？
• A. 論文の中で使った実験設定が異なるからです。

5.20 付録 今後のキャリアパスは？

研究者押しで押しまくる大学あるいは企業の研究者迷うことなくパッと答える

5.21 付録 今後の研究計画が、インパクトの少ない今までの延長のように見えるんだけど…

5.22 付録 アドホックな解法に見えるんだけど …

5.23 付録 失敗しそうなんだけど …

5.24 付録?? とにかくまとはずれな質問

引き出しを探るタイプの質問

上席研究員主任研究員

senior engineer

4段階

下 associate XX senior principal 上

PI principal investigator

time sink